

## **CHAPITRE 5 : LES MODELES A CHOIX ORDONNES**

### **SECTION 1 : Exemple : le choix d'éducation post-secondaire (suite du chapitre 3)**

Base de données : EDUCATION.XLS

N=1000 individus

Variable endogène :

$$y = \begin{cases} 1 & \text{pas au collège} \\ 2 & \text{2 ans au collège} \\ 3 & \text{4 ans au collège} \end{cases}$$

Variables exogènes :

**ETCATHO** = 1 si études secondaires catholiques

**NIVEAU** = index moyen en mathématiques, anglais et études sociales sur échelle de 13 points avec 1 le plus élevé et 13 le plus faible

**REVENU** = revenu familial brut en \$

**PERSON** = Nombre de personnes dans la famille

**DIPARENT** = 1 si la plupart des parents formés étaient diplômés du collège ou avaient un diplôme plus élevé

**FEMME** = 1 si femme, 0 si homme

**NOIR** = 1 si noir, 0 si autres

On va transformer l'énoncé précédent de la façon suivante :

Base de données : EDUCATION.XLS

N=1000 individus


Variable endogène :

$$y = \begin{cases} 1 & \text{pas au collège} & \text{mauvaise performance} \\ 2 & \text{2 ans au collège} & \text{moyen} \\ 3 & \text{4 ans au collège} & \text{super performance} \end{cases}$$

Nous avons donc ordonné nos réponses de la forme : 3 TB, 2 M et 1 N (N pour Nul). C'est notre ressenti.

$$y = \begin{cases} 1 & \text{N} \\ 2 & \text{M} \\ 3 & \text{TB} \end{cases}$$

Représentons cette variable i.e notre ressenti vis-à-vis des études dans le temps sous forme de seuil :



Nous devons rechercher ces 2 seuils :

$$y = \begin{cases} 1 & \text{si } y^* \leq S1 \\ 2 & \text{si } S1 \leq y^* \leq S2 \\ 3 & \text{si } y^* \geq S2 \end{cases}$$

$y^*$  représente une variable latente, notre ressenti vis-à-vis de notre jugement, de notre classement. C'est une variable inobservable.

Variables exogènes :

**NIVEAU** = index moyen en mathématiques, anglais et études sociales sur échelle de 13 points avec 1 le plus élevé et 13 le plus faible

NB : on pourrait aussi garder d'autres variables exogènes.

## SECTION 2 : Ecriture du modèle

Nous devons estimer le modèle suivant :

$$y^* = \beta \text{ niveau} + \epsilon$$

Comme  $y^*$  est inconnu, ce n'est pas un modèle de régression standard. On appelle ce modèle le modèle à index.

Il y a 3 alternatives, ce qui implique donc 2 seuils à chercher. La constante ne peut pas être présente car il y a multicollinéarité parfaite avec les seuils.

Comment estimer ce modèle ? Nous avons deux possibilités :

- 1) Par le modèle **PROBIT** ordonné,
- 2) Par le modèle **LOGIT** ordonné.

Choisissons le modèle **LOGIT** (totalement arbitraire).

### SECTION 3 : Formules des probabilités et des effets marginaux

Les probabilités des choix sont données par :

$$p(y = 1) = \varphi(S1 - \beta \text{ niveau})$$

$$p(y = 2) = \varphi(S2 - \beta \text{ niveau}) - \varphi(S1 - \beta \text{ niveau})$$

$$p(y = 3) = 1 - \varphi(S2 - \beta \text{ niveau})$$

Nb : calculs détaillés

$$p(y = 1) = p(y^* \leq S1) = p(\beta \text{ niveau} + \varepsilon \leq S1)$$

$$= p(\varepsilon \leq S1 - \beta \text{ niveau}) = \varphi(S1 - \beta \text{ niveau})$$

On en déduit les effets marginaux :

$$\frac{dp(y = 1)}{dniveau} = -\phi(S1 - \beta niveau) * \beta$$

$$\frac{dp(y = 2)}{dniveau} = [\phi(S1 - \beta niveau) - \phi(S2 - \beta niveau)] * \beta$$

$$\frac{dp(y = 3)}{dniveau} = \phi(S2 - \beta niveau) * \beta$$

#### **SECTION 4 : Estimations**

Par SAS 9.4 fichier EDUCATION2.SAS

Model Fit Summary	
Number of Endogenous Variables	1
Endogenous Variable	Y
Number of Observations	1000
Missing Values	2
Log Likelihood	-877.29561
Maximum Absolute Gradient	1.7664E-6
Number of Iterations	10
Optimization Method	Quasi-Newton
AIC	1761
Schwarz Criterion	1775

Mesures du critère qualitatif de lissage		
Mesure	Valeur	Formule
Likelihood Ratio (R)	282.72	$2 * (\text{LogL} - \text{LogL0})$
Upper Bound of R (U)	2037.3	$-2 * \text{LogL0}$
Aldrich-Nelson	0.2204	$R / (R+N)$
Cragg-Uhler 1	0.2463	$1 - \exp(-R/N)$
Cragg-Uhler 2	0.2832	$(1 - \exp(-R/N)) / (1 - \exp(-U/N))$
Estrella	0.2624	$1 - (1 - R/U)^{(U/N)}$
Adjusted Estrella	0.2573	$1 - ((\text{LogL} - K) / \text{LogL0})^{(-2/N * \text{LogL0})}$
McFadden's LRI	0.1388	$R / U$
Veall-Zimmermann	0.3286	$(R * (U + N)) / (U * (R + N))$
McKelvey-Zavoina	0.5717	
N = # d'observations, K = # de régresseurs		

Algorithm converged.

Résultats estimés des paramètres					
Paramètre	DDL	Valeur estimée	Erreur type	Valeur du test t	Approx. de Pr >  t
NIVEAU	1	-0.510148	0.033926	-15.04	<.0001
_Limit1	1	-4.916916	0.267263	-18.40	<.0001
_Limit2	1	-3.477195	0.241669	-14.39	<.0001

Obs.	Y	NIVEAU	Meff_P1_NIVEAU	Meff_P2_NIVEAU	Meff_P3_NIVEAU	Prob1_Y	Prob2_Y	Prob3_Y
1001	.	6.64	0.074663	0.052617	-0.12728	0.17806	0.29950	0.52244
1002	.	2.635	0.013553	0.034764	-0.04832	0.02731	0.07862	0.89407

### Interprétations :

Avec un niveau de 6.64 (la médiane), [élève médian], la probabilité de ne pas aller au collège est de 17.80%, 29.95% de rester 2 ans au collège et 52.24% de rester 4 ans au collège.

Pour un bon élève (niveau de 2.635), les probabilités sont 2.7% pour 1, 7.8% pour 2 et 89% pour 3.

A comparer avec (Cf. chapitre 3) :

#### Effets marginaux (au point median)

Obs.	p1	p2	p3	em1	em2	em3
1	0.18101	0.28558	0.53341	0.084148	0.044574	-0.12872

#### Effets marginaux (au point 5ième décile)

Obs.	p1	p2	p3	em1	em2	em3
1	0.017766	0.096545	0.88569	0.011642	0.033452	-0.045094